Travail Personnel
Cours

Cours Complet SQL

By :
Rémy Gasmi

19 mars 2025

Table des matières

1 Les bases de données relationnelles

1.1 Définition

Une base de données est une collection organisée d'informations ou de données, structurée de manière à pouvoir être facilement accédée, gérée et mise à jour.

Les données sont présentes dans tous les domaines, que ce soit le football, le cinéma ou les diverses professions. Une base de données constitue un moyen efficace de structurer ces informations, facilitant ainsi leur accès et leur utilisation.

1.2 Qu'est-ce que SQL ?

Le SQL, Structured Query Language, est un langage Standard permettant à un client de communiquer des instructions à une base de données. Il se décline en quatre parties :

— le DDL (Data definition language) comporte les instructions qui permettent de définir la façon dont les données sont représentées.

— le DML (Data manipulation language) permet d'écrire dans la base et donc de modifier les données.

— le DQL (Data query language) est la partie la plus complexe du SQL, elle permet de lire les données dans la base à l'aide de requêtes.

— le DCL (Data control language) permet de gérer les droits d'accès aux données.

A cela s'ajoute des extensions procédurales du SQL (appelé PL/SQL en Oracle). Celui-ci permet d'écrire des scripts exécutés par le serveur de base de données.

Dans ce cours, nous allons nous pencher en grande partie sur le DQL et nous verrons une partie du DML.

1.3 Pourquoi le SQL ?

Souvent les données sont stockées dans des fichiers de type **.csv**.
Cela peut poser des problèmes si plusieurs personnes doivent travailler sur ce fichier, car chaque utilisateur doit le charger pour l'utiliser.

En plus, il devient compliqué de gérer les modifications apportées par chacun : comment s'assurer que toutes les modifications soient prises en compte ?

Enfin, dans des situations qui nécessitent beaucoup de données, stocker toutes les informations dans un seul tableau n'est pas optimale.

C'est pour ces raisons que le SQL existe et c'est pour cela qu'on parle de base de donnée relationnelle : pour faire communiquer les bases de données (qui sont donc des tableaux) entre elles avec un langage de requête simple.

1.4 Différents modèles

Il existe divers modèles de bases de données :

- Les **bases de données relationnelles** utilisent des tableaux de données organisés en lignes et colonnes auxquelles on accède grâce au langage **SQL**.
- Les **bases de données non-relationnelles** dites **noSQL** qui peuvent stocker des données de formes diverses comme des graphes, des documents, etc.

Dans ce cours, nous ne nous intéresserons qu'aux bases de données relationnelles et au langage SQL.

Dans une base de donnée relationnelle, plutôt que de stocker toutes les données dans une table, on les stocke dans plusieurs tables reliées entre elles par des clés.

Une base de données est définie par son schéma relationnel qui spécifie :

- La liste des tables avec pour chaque table :
  - Le nom de la table (appelée relation)
  - La liste des colonnes (appelées attributs) avec leur nom et le domaine de valeurs des données qui y sont stockées (entiers, chaînes de caractères, dates, etc.)
  - Les identifiants (qui sont uniques) de chaque ligne
- Les tables doivent être reliées entre elles grâce à des identifiants secondaires

1.5 Les différents systèmes de gestion de bases de données relationnelles

MySQL et SQL Server sont tous deux des systèmes de gestion de bases de données relationnelles à hautes performances. Vous devez considérer les deux bases de données comme puissantes, évolutives et fiables.

SQL Server propose un optimiseur de requêtes et des index de type « columnstore » pour optimiser les performances. À mesure que vous augmentez la charge de travail des bases de données, les performances de SQL Server sont généralement légèrement supérieures à celles de MySQL.

MySQL utilise le regroupement de connexions et la mise en cache des requêtes pour optimiser les performances.

1.6 Les différents types de données

Les principaux types de données en SQL sont :

- CHARACTER (ou CHAR) : valeur alpha de longueur fixe.
- CHARACTER VARYING (ou VARCHAR) : valeur alpha de longueur maximale fixée.
- NATIONAL CHARACTER VARYING (ou NVARCHAR) : Contrairement au type VARCHAR, qui stocke les caractères selon un encodage dépendant de la page de code (non Unicode), NVARCHAR utilise un encodage Unicode (UTF-16 ou UCS-2 selon la version de SQL Server), permettant de gérer correctement un large éventail de langues et de symboles.
- TEXT : suite longue de caractères (sans limite de taille).
- FLOAT : 32 bits (1 bit de signe, 8 bits d'exposant, 23 bits de mantisse), environ 6 à 7 chiffres significatifs
- DOUBLE : 64 bits (1 bit de signe, 11 bits d'exposant, 52 bits de mantisse), environ 15 à 16 chiffres significatifs.
- INTEGER (ou INT) : entier long
- BIGINT : entier de généralement 64 bits (8 octets).
- REAL : réel à virgule flottante dont la représentation est binaire.
- BOOLEAN (ou LOGICAL) : vrai/faux
- BIT : (0 ou 1) dans certains SGBD.
- DATE : Date du calendrier grégorien.
- TIME : Stocke l'heure (heures, minutes, secondes) avec éventuellement une précision (microsecondes ou nanosecondes selon le SGBD).
- DATETIME : Combine la date et l'heure.
- TIMESTAMP : gère souvent un intervalle plus restreint que DATETIME mais est souvent associé au fuseau horaire ou capable d'enregistrer l'information de date/heure sous forme de nombre de secondes écoulées depuis une référence (Unix epoch).

Il y en a évidemment d'autres, mais c'est une bonne introduction. Voir le lien suivant :

`https://webusers.i3s.unice.fr/~rueher/Cours/BD/DocPostgresSQL9-5_HTML/datatype.html`

2 Sélection de données

Une requête SQL est une série d'instructions basiques utilisant des mots anglais tels que `SELECT`, `FROM`, etc.
Vous remarquerez qu'ils sont toujours écrits en majuscules.
La structure générale de la majorité des commandes SQL est de la forme :

```
SELECT liste des attributs
FROM table_name ;
WHERE liste des conditions
GROUP BY expression
HAVING condition
UNION | INTERSECT | EXCEPT
ORDER BY expression
LIMIT count
OFFSET start ;
```

Attention : Il est vraiment primordiale de respecter l'ordre et d'ajouter un point virgule" **;**" à la fin de la requête.

En SQL, le point-virgule (**;**) est utilisé pour marquer la fin d'une instruction. C'est un séparateur de commandes qui permet à l'interpréteur SQL de comprendre où se termine une commande et où commence la suivante. C'est donc une habitude à prendre pour ce langage.

L'ordre d'écriture de nos requêtes SQL n'est pas le même que leur ordre d'exécution, et c'est crucial de le comprendre pour optimiser nos performances.

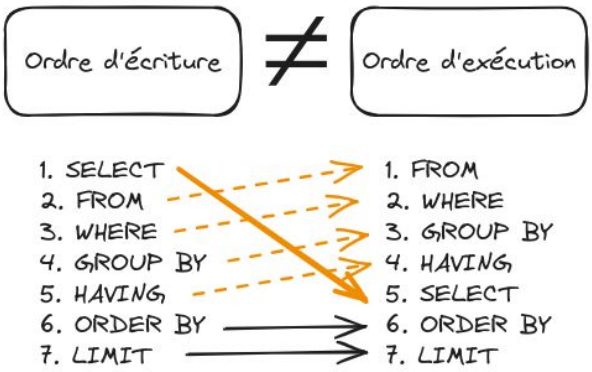

Ainsi :

— Ordre d'écriture : SELECT → FROM → WHERE → GROUP BY → HAVING → ORDER BY → LIMIT

— Ordre d'exécution : FROM → WHERE → GROUP BY → HAVING → SELECT → ORDER BY → LIMIT

Pourquoi c'est important ? Prenons un exemple concret : Si vous filtrez vos données avec WHERE avant de faire un GROUP BY, vous économisez des ressources en n'agrégeant que les données pertinentes.

Gardez toujours cet ordre en tête lors de l'optimisation de vos requêtes. Cela peut faire une différence significative sur les performances, particulièrement avec de gros volumes de données.

2.1 SELECT

L'utilisation la plus courante de SQL consiste à lire des données issues de la base de données. Cela s'effectue avec la requête **SELECT** qui permet d'afficher les colonnes sélectionnées.

Avec cette dernière, on peut sélectionner une ou plusieurs colonnes d'une table.

Voici un exemple :

```
SELECT col1, col2
FROM table_name;
```

Cette requête va sélectionner (SELECT) les colonnes "col1", "col2" provenant (FROM) de la table appelée "table_name".

Si on veut afficher toutes les colonnes d'une table, on utilisera le caractère "*"(étoile) :

```
SELECT *
FROM table_name;
```

2.1.1 SELECT DISTINCT

La requête `SELECT DISTINCT` permet de sélectionner des valeurs uniques dans une colonne ou une combinaison de colonnes, en éliminant les doublons des résultats.
Pour le Système de Gestion de Bases de Données (SGBD) Oracle, cette requête est remplacée par la commande `UNIQUE`.

2.2 FROM

Pour chaque commande, il est nécessaire de spécifier dans quelle table rechercher les informations. Cela se fait avec l'instruction **FROM**. C'est pourquoi vous la voyez et verrez dans toutes les commandes qui suivent.

2.3 WHERE

La commande WHERE dans une requête SQL permet d'extraire les lignes d'une base de données qui respectent une condition. Cela permet d'obtenir uniquement les informations désirées.

On l'utilise de la manière suivante :

```
SELECT nom_colonnes
FROM table_name
WHERE condition;
```

La condition est toujours de la forme :

```
Colonne Opérateur_de_comparaison la_condition
```

2.3.1 Les opérateurs de comparaisons

Il existe plusieurs opérateurs de comparaisons. La liste ci-jointe présente quelques uns des opérateurs les plus couramment utilisés.

Opérateur	Description
=	Égale
<>	Pas égale
!=	Pas égale
>	Supérieur à
<	Inférieur à
>=	Supérieur ou égale à
<=	Inférieur ou égale à
IN	Liste de plusieurs valeurs possibles
BETWEEN	Valeur comprise dans un intervalle donnée (utile pour les nombres ou dates)
LIKE	Recherche en spécifiant le début, milieu ou fin d'un mot.
IS NULL	Valeur est nulle
IS NOT NULL	Valeur n'est pas nulle

2.4 GROUP BY

La commande `GROUP BY` est utilisée en SQL pour grouper plusieurs résultats et utiliser une fonction de totaux sur un groupe de résultat. Sur une table qui contient toutes les ventes d'un magasin, il est par exemple possible de regrouper les ventes par clients identiques et d'obtenir le coût total des achats pour chaque client.

La syntaxe de la commande est :

```
SELECT colonne1, fonction(colonne2)
FROM table_name
GROUP BY colonne1 ;
```

A noter : cette commande doit toujours s'utiliser après la commande WHERE et avant la commande `HAVING`.

2.5 HAVING

La condition `HAVING` en SQL est presque similaire à `WHERE` à la seule différence que `HAVING` permet de filtrer en utilisant des fonctions telles que SUM(), COUNT(), AVG(), MIN() ou MAX() (voir section Fonctions utiles et classiques).

L'utilisation de `HAVING` s'utilise de la manière suivante :

```
SELECT colonne1, SUM(colonne2)
FROM table_name
GROUP BY colonne1
HAVING fonction(colonne2) operateur valeur ;
```

Cela permet donc de SÉLECTIONNER les colonnes DE la table "table_name" en GROUPANT les lignes qui ont des valeurs identiques sur la colonne "colonne1" et que la condition de `HAVING` soit respectée.

Important : `HAVING` est très souvent utilisé en même temps que `GROUP BY` bien que ce ne soit pas obligatoire.

Dans les consignes, on pensera à faire un `HAVING` dans les phrases types "affichez les profs qui ont plus de 5 qqch".

2.6 ORDER BY

La commande `ORDER BY` permet de trier les lignes dans un résultat d'une requête SQL. Il est possible de trier les données sur une ou plusieurs colonnes, par ordre ascendant ou descendant.

Une requête où l'on souhaite filtrer l'ordre des résultats utilise la commande `ORDER BY` de la sorte :

```
SELECT colonne1, colonne2
FROM table_name
ORDER BY colonne1 ;
```

Par défaut les résultats sont classés par ordre ascendant, toutefois il est possible d'inverser l'ordre en utilisant le suffixe DESC après le nom de la colonne. Par ailleurs, il est possible de trier sur plusieurs colonnes en les séparant par une virgule. Une requête plus élaborée ressemblerait à cela :

```
SELECT colonne1, colonne2, colonne3
FROM table_name
ORDER BY colonne1 DESC, colonne2 ASC;
```

A noter : il n'est pas obligé d'utiliser le suffixe "ASC" sachant que les résultats sont toujours classés par ordre ascendant par défaut. Toutefois, c'est plus pratique pour mieux s'y retrouver, surtout si on a oublié l'ordre par défaut.

2.7 LIMIT

La clause `LIMIT` est à utiliser dans une requête SQL pour spécifier le nombre maximum de résultats que l'on souhaite obtenir. Cette clause est souvent associée à un OFFSET, c'est-à-dire effectuer un décalage sur le jeu de résultat. Ces 2 clauses permettent par exemple d'effectuer des systèmes de pagination (exemple : récupérer les 10 articles de la page 4).

ATTENTION : selon le système de gestion de bases de données, la syntaxe ne sera pas pareille.

La syntaxe est :

```
SELECT *
FROM table_name;
LIMIT 10;
```

Cette requête permet de récupérer seulement les 10 premiers résultats d'une table. Bien entendu, si la table contient moins de 10 résultats, alors la requête retournera toutes les lignes.

Bon à savoir : la bonne pratique lorsque l'on utilise LIMIT consiste à utiliser également la clause ORDER BY pour s'assurer que quoi qu'il en soit ce sont toujours les bonnes données qui sont présentées. En effet, si le système de tri est non spécifié, alors il est en principe inconnu et les résultats peuvent être imprévisibles.

2.7.1 Limit et Offset

L'offset est une méthode simple de décaler les lignes à obtenir. La syntaxe PostgreSQL pour utiliser une limite et un offset est la suivante :

```
SELECT *
FROM table_name;
LIMIT 10 OFFSET 5;
```

Cette requête permet de récupérer les résultats 6 à 15 (car l'OFFSET commence toujours à 0). A titre d'exemple, pour récupérer les résultats 16 à 25 il faudrait donc utiliser : LIMIT 10 OFFSET 15.

A noter : Utiliser OFFSET 0 reviens au même que d'omettre l'OFFSET.

En MySQL, la syntaxe est légèrement différente :

```
SELECT *
FROM table_name;
LIMIT 5, 10;
```

Cette requête retourne les enregistrements 6 à 15 d'une table. Le premier nombre est l'OFFSET tandis que le suivant est la limite.

Bon à savoir : pour une bonne compatibilité, MySQL accepte également la syntaxe LIMIT nombre OFFSET nombre. En conséquent, dans la conception d'une application utilisant MySQL il est préférable d'utiliser cette syntaxe car c'est potentiellement plus facile de migrer vers un autre système de gestion de base de données sans avoir à ré-écrire toutes les requêtes.

3 Fonctions utiles et classiques (Fonctions d'agrégation)

3.1 COUNT()

En SQL, la fonction d'agrégation `COUNT()` permet de compter le nombre d'enregistrement dans une table.

Connaître le nombre de lignes dans une table est très pratique dans de nombreux cas, par exemple pour savoir combien d'utilisateurs sont présents dans une table ou pour connaître le nombre de commentaires sur un article.

En voici un exemple :

```
SELECT COUNT(*)
FROM table;
```

A savoir : en général, en termes de performance il est plutôt conseillé de filtrer les lignes avec GROUP BY si c'est possible, puis d'effectuer un COUNT(*).

On pourra également associer le mot clé `DISTINCT` à `COUNT()` afin de compter distinctement les entités :

```
SELECT COUNT(DISTINCT expression)
FROM table;
```

3.2 SUM()

La fonction d'agrégation `SUM()` permet de calculer la somme totale d'une colonne contenant des valeurs numériques. Cette fonction n'est utile que sur des colonnes de types numériques (INT, FLOAT ...) et n'additionne pas les valeurs NULL.

La syntaxe pour utiliser cette fonction SQL peut être similaire à celle-ci :

```
SELECT SUM(nom_colonne)
FROM table;
```

Cette requête SQL permet de calculer la somme des valeurs contenues dans la colonne "nom_colonne".

A savoir : Il est possible de filtrer les enregistrements avec la commande `WHERE` pour ne calculer la somme que des éléments souhaités.

3.3 AVG()

La fonction d'agrégation `AVG()` dans le langage SQL permet de calculer une valeur moyenne sur un ensemble d'enregistrement de type numérique et non nul.

Syntaxe :

```
SELECT AVG(nom_colonne)
FROM nom_table;
```

Cette requête permet de calculer la note moyenne de la colonne "nom_colonne" sur tous les enregistrements de la table "nom_table". Il est possible de filtrer les enregistrements concernés à l'aide de la commande `WHERE`. Il est aussi possible d'utiliser la commande `GROUP BY` pour regrouper les données appartenant à la même entité.

3.4 ROUND()

La fonction `ROUND()` permet d'arrondir un résultat numérique. Cette fonction permet soit d'arrondir sans utiliser de décimale pour retourner un nombre entier (c'est-à-dire : aucun chiffre après la virgule), ou de choisir le nombre de chiffres après la virgule.

Syntaxe :

```
SELECT ROUND(nom_colonne)
FROM table;
```

Dans cet exemple la colonne "nom_colonne" contient des données numériques (exemple : FLOAT, INT, NUMERIC ...) et retournera uniquement des entiers.

Pour obtenir le résultat avec 2 chiffres de décimal il convient de spécifier le nombre de décimal souhaité comme 2ème argument :

```
SELECT ROUND(nom_colonne, 2)
FROM table;
```

3.5 ISNULL()

Dans le langage SQL la fonction `ISNULL()` peut s'avérer utile pour traiter des résultats qui possèdent des données nulles. Attention toutefois, cette fonction s'utilise différemment selon le système de gestion de bases de données :

- MySQL : la fonction ISNULL() prend un seul paramètre et permet de vérifier si une données est nulle
- SQL Server : la fonction ISNULL() prend 2 paramètres et sert à afficher la valeur du 2ème paramètre si le premier paramètre est null. Cette même fonctionnalité peut être effectuée par d'autres systèmes de gestion de base de données d'une manière différente :
  - MySQL : il faut utiliser la fonction IFNULL()
  - PostgreSQL : il faut utiliser la fonction COALESCE()

— Oracle : il faut utiliser la fonction NVL()

Voici un lien pour creuser : `https://sql.sh/fonctions/isnull`

3.6 MAX()

La fonction d'agrégation `MAX()` permet de retourner la valeur maximale d'une colonne dans un set d'enregistrement. La fonction peut s'appliquer à des données numériques ou alphanumériques. Il est par exemple possible de rechercher le produit le plus cher dans une table d'une boutique en ligne.

Syntaxe :

```
SELECT MAX(nom_colonne)
FROM table;
```

Lorsque cette fonctionnalité est utilisée en association avec la commande `GROUP BY`, la requête peut ressembler à l'exemple ci-dessous :

```
SELECT colonne1, MAX(colonne2)
FROM table
GROUP BY colonne1;
```

3.7 MIN()

La fonction d'agrégation `MIN()` de SQL permet de retourner la plus petite valeur d'une colonne sélectionnée. Cette fonction s'applique aussi bien à des données numériques qu'à des données alphanumériques et s'utilise comme la fonction `MAX()`.

4 Jointures

Les jointures permettent de regrouper des jeux de données. Elles sont essentielles pour l'extraction d'information quand on a plusieurs jeux de données.

On va donc avec ces jointures pouvoir exploiter les relations entre les différentes bases de données.

De manière générale, on écrira :

```
SELECT *
FROM table1
(LEFT)(RIGHT)JOIN table2
ON table1.colonne_i = table2.colonne_j;
```

4.1 JOIN/INNER JOIN

En SQL standard moderne, `JOIN` est un alias pour `INNER JOIN`, donc il n'y a aucune différence pratique.

Cette commande sélectionne uniquement les lignes où il existe une correspondance dans les deux tables impliquées dans la jointure.

On notera que certains SGBD anciens ou spécifiques (comme Oracle dans ses versions historiques) peuvent exiger que l'utilisateur précise explicitement `INNER JOIN` pour éviter toute ambiguïté.

4.2 LEFT JOIN

`LEFT JOIN` permet de récupérer toutes les lignes de la table de gauche (table1), ainsi que les lignes correspondantes de la table de droite (table2). Si aucune correspondance n'est trouvée dans la table de droite, les colonnes de celle-ci contiendront des valeurs `NULL`.

On l'utilisera donc lorsque l'on souhaite conserver toutes les données d'une table principale (table1), même si elles n'ont pas de correspondance dans une autre table.

4.3 RIGHT JOIN

`RIGHT JOIN` récupère toutes les lignes de la table de droite (table2), ainsi que les lignes correspondantes de la table de gauche (table1). Si aucune correspondance n'est trouvée dans la table de gauche, les colonnes de celle-ci contiendront des valeurs `NULL`.

4.4 FULL OUTER JOIN

Cette jonction combine les résultats d'un `LEFT JOIN` et d'un `RIGHT JOIN`.

On peut alors récupérer toutes les lignes des deux tables, en insérant des `NULL` pour les colonnes de la table opposée lorsqu'il n'y a pas de correspondance.

4.5 CROSS JOIN

Cette jonction réalise le produit cartésien des deux tables, c'est-à-dire qu'il associe chaque ligne de la première table avec chaque ligne de la seconde table.

4.6 Récapitulatif

<table>
<tr><th>Tables en entrée</th><th>Type de jointure</th><th>Requête SQL</th><th>Résultat</th></tr>
<tr><td rowspan="4">
<table><tr><th colspan="2">Table 1</th></tr><tr><th>id</th><th>nom</th></tr><tr><td>1</td><td>a</td></tr><tr><td>2</td><td>b</td></tr><tr><td>3</td><td>c</td></tr></table>
<table><tr><th colspan="2">Table 2</th></tr><tr><th>id</th><th>valeur</th></tr><tr><td>1</td><td>xxx</td></tr><tr><td>3</td><td>yy</td></tr><tr><td>3</td><td>yyyy</td></tr><tr><td>5</td><td>zzz</td></tr></table>
</td><td>Croisée
CROSS JOIN
Pas de critère de jointure</td><td>SELECT *
FROM table1 AS t1
CROSS JOIN table2 AS t2 ;</td><td>
<table><tr><th>t1.id</th><th>t1.nom</th><th>t2.id</th><th>t2.valeur</th></tr><tr><td>1</td><td>a</td><td>1</td><td>xxx</td></tr><tr><td>1</td><td>a</td><td>3</td><td>yy</td></tr><tr><td>1</td><td>a</td><td>3</td><td>yyyy</td></tr><tr><td>1</td><td>a</td><td>5</td><td>zzz</td></tr><tr><td>2</td><td>b</td><td>1</td><td>xxx</td></tr><tr><td>2</td><td>b</td><td>3</td><td>yy</td></tr><tr><td>2</td><td>b</td><td>3</td><td>yyyy</td></tr><tr><td>2</td><td>b</td><td>5</td><td>zzz</td></tr><tr><td>3</td><td>c</td><td>1</td><td>xxx</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yy</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yyyy</td></tr><tr><td>3</td><td>c</td><td>5</td><td>zzz</td></tr></table>
</td></tr>
<tr><td>Complète
FULL JOIN
Nécessité d'avoir un critère de jointure</td><td>SELECT *
FROM table1 AS t1
FULL JOIN table2 AS t2
ON t1.id = t2.id ;</td><td>
<table><tr><th>t1.id</th><th>t1.nom</th><th>t2.id</th><th>t2.valeur</th></tr><tr><td>1</td><td>a</td><td>1</td><td>xxx</td></tr><tr><td>2</td><td>b</td><td></td><td></td></tr><tr><td>3</td><td>c</td><td>3</td><td>yy</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yyyy</td></tr><tr><td></td><td></td><td>5</td><td>zzz</td></tr></table>
</td></tr>
<tr><td>À gauche
LEFT JOIN
Nécessité d'avoir un critère de jointure</td><td>SELECT *
FROM table1 AS t1
LEFT JOIN table2 AS t2
ON t1.id = t2.id ;</td><td>
<table><tr><th>t1.id</th><th>t1.nom</th><th>t2.id</th><th>t2.valeur</th></tr><tr><td>1</td><td>a</td><td>1</td><td>xxx</td></tr><tr><td>2</td><td>b</td><td></td><td></td></tr><tr><td>3</td><td>c</td><td>3</td><td>yy</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yyyy</td></tr></table>
</td></tr>
<tr><td>À droite
RIGHT JOIN
Nécessité d'avoir un critère de jointure</td><td>SELECT *
FROM table1 AS t1
RIGHT JOIN table2 AS t2
ON t1.id = t2.id ;</td><td>
<table><tr><th>t1.id</th><th>t1.nom</th><th>t2.id</th><th>t2.valeur</th></tr><tr><td>1</td><td>a</td><td>1</td><td>xxx</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yy</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yyyy</td></tr><tr><td></td><td></td><td>5</td><td>zzz</td></tr></table>
</td></tr>
<tr><td></td><td>Naturelle
JOIN
Nécessité d'avoir un critère de jointure</td><td>SELECT *
FROM table1 AS t1
JOIN table2 AS t2
ON t1.id = t2.id ;</td><td>
<table><tr><th>t1.id</th><th>t1.nom</th><th>t2.id</th><th>t2.valeur</th></tr><tr><td>1</td><td>a</td><td>1</td><td>xxx</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yy</td></tr><tr><td>3</td><td>c</td><td>3</td><td>yyyy</td></tr></table>
</td></tr>
</table>

Les espaces vides sont en fait des NULL.

5 CTE(Common Table Expression)

5.1 Présentation des CTE

Une expression de table commune (CTE) est comme une sous-requête nommée. Elle fonctionne comme une table virtuelle à laquelle seule la requête principale peut accéder. Les CTE permettent de simplifier, de raccourcir et d'organiser votre code.

On les définit dans une requête SQL à l'aide du mot-clé : `WITH` .

Voici la syntaxe :

```
WITH my_cte AS(
    SELECT a,b,c
    FROM T1)

SELECT a,c
FROM my_cte
WHERE ...
```

Le nom de cette CTE est my_cte et la requête CTE est SELECT a,b,c FROM T1.

L'ETC commence par le mot-clé WITH, après quoi vous indiquez le nom de votre ETC, puis le contenu de la requête entre parenthèses. La requête principale vient après la parenthèse fermante et fait référence à l'ETC. Ici, la requête principale (également appelée requête externe) est SELECT a,c FROM my_cte WHERE ....

Étudions un exemple :

branch	date	seller	item	quantity	unit_price
Paris-1	2021-12-07	Charles	Headphones A2	1	80
London-1	2021-12-06	John	Cell Phone X2	2	120
London-2	2021-12-07	Mary	Headphones A1	1	60
Paris-1	2021-12-07	Charles	Battery Charger	1	50
London-2	2021-12-07	Mary	Cell Phone B2	2	90
London-1	2021-12-07	John	Headphones A0	5	75
London-1	2021-12-07	Sean	Cell Phone X1	2	100

Pour obtenir le prix de l'article le plus cher, nous utilisons une expression de table commune comme celle-ci :

```
WITH highest AS (
    SELECT
        branch,
        date,
        MAX(unit_price) AS highest_price
    FROM sales
    GROUP BY branch, date)

SELECT sales.*, h.highest_price
FROM sales
JOIN highest h
ON sales.branch = h.branch
    AND sales.date = h.date;
```

Important : La plupart des fonctions des CTE dans SQL Server peuvent être réalisées avec une sous-requête. Mais imaginez à quoi ressembleraient les codes... Ce ne serait pas très lisible !

L'une des utilisations typiques des CTE dans SQL Server permet donc de vous aider à organiser les longues requêtes. Les CTEs rendent les requêtes plus lisibles en nommant les parties de la requête. Ainsi, vous pouvez facilement décomposer chaque partie d'un calcul complexe et rendre le calcul logique.

Il n'y a pas de secrets, pour vraiment les comprendre, il faut s'exercer ! Voici quelques liens :

- `https://learnsql.fr/blog/11-exercices-d-expression-de-table-commune-sql/`
- Problème Leetcode : 550. Game Play Analysis IV
- Problème Leetcode : 1070. Product Sales Analysis III

5.2 Plusieurs CTE

IMPORTANT :

Si j'ai plusieurs cte à taper, je n'utiliserai qu'un seul With. Ensuite je sépare mes cte avec une simple virgule Enfin je tape la commande principale. Cela donne :

5.3 UNION ALL

6 Les requêtes temporelles et les dates

Il est important en SQL de pouvoir connaître la date et l'heure. Il existe une multitude de fonctions qui concernent les éléments temporels pour pouvoir lire ou écrire plus facilement des données à une date précise ou à un intervalle de date.

Ces requêtes sont cruciales pour l'analyse de séries temporelles, le calcul de KPIs basés sur le temps, ou l'identification de tendances saisonnières.

6.1 DATE_FORMAT()

La fonction `DATE_FORMAT()`, dans le langage SQL et plus particulièrement avec MySQL, permet de formater une donnée DATE dans le format indiqué. Il s'agit de la fonction idéal si l'on souhaite définir le formatage de la date directement à partir du langage SQL et pas uniquement dans la partie applicative. Voici sa syntaxe :

```
SELECT DATE_FORMAT(date, format)
```

Le premier paramètre correspond à une donnée de type DATE (ou DATETIME), tandis que le deuxième paramètre est une chaîne de caractère contenant le choix de formatage **(voir page suivante)**.

Il est évidement possible de combiner plusieurs valeurs de formatage afin d'obtenir le formatage d'une date dans le format de son choix.

Quelques exemples :

— SELECT DATE_FORMAT("2018-09-24", "%D %b %Y") donne "24th Sep 2018"
— SELECT DATE_FORMAT("2018-09-24 22 :21 :20", "%H :%i :%s") donne "22 :21 :20"
— SELECT DATE_FORMAT("2018-09-24", "Message du : %d/%m/%Y") donne "Message du : 24/09/2018"

Et donc vis à vis d'une colonne entière on écrira par exemple :

```
SELECT *, DATE_FORMAT(date_inscription, "%d/%m/%Y")
FROM utilisateur ;
```

La requête ci-dessus permet d'obtenir la liste des données d'une table contenant des utilisateurs, ainsi que la date d'inscription avec un formatage jour/mois/année prêt à être exploité affiché dans un format facile à lire pour les utilisateurs.

Voici tous les formats possibles :

— %a : nom du jour de la semaine abrégé (Sun, Mon, ... Sat)
— %b : nom du mois abrégé (Jan, Fev, ... Dec)
— %c : numéro du mois (0, 1, 2, ... 12) (numérique)
— %D : numéro du jour, avec le suffixe anglais (0th, 1st, 2nd, 3rd, ...)
— %d : numéro du jour du mois, sous 2 décimales (00..31) (numérique)
— %e : numéro du jour du mois (0..31) (numérique)
— %f : microsecondes (000000..999999)
— %H : heure (00..23)
— %h : heure (01..12)
— %I : heure (01..12)
— %i : minutes (00..59) (numérique)
— %j : jour de l'année (001..366)
— %k : heure (0..23)
— %l : heure (1..12)
— %M : nom du mois (January..December)
— %m : mois (00..12) (numérique)
— %p : AM ou PM
— %r : heure au format 12-heures (hh :mm :ss suivi par AM ou PM)
— %S : secondes (00..59)
— %s : secondes (00..59)
— %T : heure au format 24 heures (hh :mm :ss)
— %U : Semaine (00..53), pour lequel le dimanche est le premier jour de la semaine ; WEEK() mode 0
— %u : Semaine (00..53), pour lequel le lundi est le premier jour de la semaine ; WEEK() mode 1
— %V : Semaine (01..53), pour lequel le dimanche est le premier jour de la semaine ; WEEK() mode 2 ; utilisé avec %X
— %v : Semaine (01..53), pour lequel le lundi est le premier jour de la semaine ; WEEK() mode 3 ; utilisé avec %x
— %W : nom du jour de la semaine (Sunday, Monday, ... Saturday)
— %w : numéro du jour de la semaine (0=dimanche, 1=lundi, ... 6=samedi)
— %X : numéro de la semaine de l'année, pour lequel le dimanche est le premier jour de la semaine, numérique, 4 digits ; utilisé avec %V
— %x : numéro de la semaine de l'année, pour lequel le lundi est le premier jour de la semaine, numérique, 4 digits ; utilisé avec %v
— %Y : année, numérique (avec 4 digits)
— %y : année, numérique (avec 2 digits)
— %% : un caractère %
— %x x, pour n'importe lequel "x" non listé ci-dessus

6.2 DATEDIFF()

La fonction `DATEDIFF` permet de déterminer l'intervalle entre 2 dates spécifiées.

La fonction est utilisée avec les systèmes MySQL et SQL Server, mais s'utilise différemment :

- MySQL : la fonction prend 2 dates en paramètres et retourne le nombre de jours entre les 2 dates
- SQL Server : la fonction prend 2 dates ainsi qu'un paramètre déterminant sous quel intervalle de distance temporelle le résultat doit être retourné (nombre de jours entre 2 dates, nombre d'années, nombre de semaines, nombre d'heures ...)

En MySQL, on tapera :

```
SELECT DATEDIFF(date1, date2);
```

Sous SQL Server, on tapera :

```
SELECT DATEDIFF( type_limite, date1, date2 );
```

Le paramètre "type_limite" permet de spécifier si le résultat doit être exprimé en jour, semaine, mois, année ... Ce paramètre utilise l'une de ses valeurs : year, quarter, month, dayofyear, day, week, weekday, hour, minute, second, millisecond, microsecond ou nanosecond.

Donc pour reproduire le même fonctionnement que la fonction DATEDIFF() de MySQL, il convient d'utiliser la valeur "day" pour le paramètre "type _limite".

6.3 DATE_ADD/DATE_SUB

`DATE_ADD` est utilisé pour ajouter un intervalle spécifique à une date au format TIME.

`DATE_SUB` est utilisé pour soustraire un intervalle spécifique à une date donnée au format TIME.

On tapera :

```
DATE_ADD(date, INTERVAL valeur unité)
```

- date : La date de départ.
- INTERVAL : Spécifie combien d'unités de temps ajouter.
- valeur : Le nombre d'unités (par exemple, jours, mois, années).
- unité : Le type d'intervalle (DAY, MONTH, YEAR, etc).

Exemple :

```
SELECT DATE_ADD('2025-01-24', INTERVAL 10 DAY) AS new_date;
```

6.4 NOW, DAY, MONTH, YEAR

6.4.1 NOW

La fonction `NOW()` en SQL est utilisée pour obtenir la date et l'heure actuelles du système de base de données. C'est une fonction courante et très pratique pour travailler avec des données temporelles. Le format de sortie dépend du SGBD, mais généralement c'est `YYYY-MM-DD HH :MM :SS`.

6.4.2 CURDATE/CURRENT_DATE

Permet d'obtenir seulement la date actuelle `YYYY-MM-DD`.
— CURDATE pour MySQL
— CURRENT_DATE pour du SQL standard

6.4.3 CURRENT_TIME

Heure actuelle uniquement `HH :MM :SS`

6.4.4 DAY

La fonction DAY extrait le jour du mois d'une date donnée. SELECT DAY('2025-01-24') AS jour donnera 24.

6.4.5 MONTH

La fonction MONTH extrait le mois (sous forme de nombre) d'une date donnée. SELECT MONTH('2025-01-24') AS mois donnera 1.

6.4.6 YEAR

La fonction YEAR extrait l'année d'une date donnée. SELECT YEAR('2025-01-24') AS annee donnera 2025.

6.5 FORMULAIRE DATE

Sur cette page, je fais un gros formulaire récapitulatif de toutes les commandes SQL pour les dates.

- AGE() soustraire 2 dates [PostgreSQL]
- ADDDATE() ajouter une période sous forme d'heures à une date [MySQL]
- ADDTIME() ajouter une période sous forme d'une date à une autre date [MySQL]
- CONVERT_TZ() convertir d'une "timezone" à une autre [MySQL]
- CURDATE() récupérer la date courante [MySQL]
- CURRENT_DATE() synonyme de CURDATE() [MySQL, PostgreSQL]
- CURRENT_TIME() synonyme de CURTIME() [MySQL, PostgreSQL]
- CURRENT_TIMESTAMP() synonyme de NOW() [MySQL, PostgreSQL, SQL Server]
- CURTIME() Return the current time [MySQL]
- DATE() extraire une date à partir d'une chaîne contenant une valeur au format DATE ou DATETIME [MySQL]
- DATE_ADD() ajouter une valeur au format TIME à une date [MySQL]
- DATE_FORMAT() formater la date pour l'afficher selon le format choisi [MySQL]
- DATE_PART() extraire un élément d'un DATETIME (cf. heure, minute, jour, mois ...) [PostgreSQL]
- DATE_SUB() soustraire une valeur au format TIME à une date [MySQL]
- DATE_TRUNC() tronquer un DATETIME avec la précision souhaitée (cf. mois, jour, heure, minute ...) [PostgreSQL]
- DATEADD() ajoute un élément (minute, heure, jour, mois, année ...) à une date spécifiée [SQL Server]
- DATEDIFF() déterminer le nombre de jours entre 2 dates [MySQL, SQL Server]
- DATENAME() retourner une partie d'une date (cf. minute, heure, jour, semaine, mois ...) [SQL Server]
- DATEPART() retourne un entier qui représente la partie d'une date (cf. minute, heure, jour, mois, année ...) [SQL Server]
- DAY() synonyme de DAYOFMONTH() [MySQL, SQL Server]
- DAYNAME() retourne le nom du jour de la semaine [MySQL]
- DAYOFMONTH() retourner le jour dans le mois (de 1 à 31) [MySQL]
- DAYOFWEEK() retourner le jour dans la semaine (1=dimanche, 2=lundi, 3=mardi ...) [MySQL]
- DAYOFYEAR() retourner le jour dans l'année (de 1 à 366) [MySQL]
- EXTRACT() extraire une partie d'une date [MySQL, PostgreSQL]
- FROM_DAYS() convertir un nombre de jour en une date [MySQL]
- FROM_UNIXTIME() convertir un timestamp UNIX en un date au format DATETIME [MySQL]
- GET_FORMAT() retourne le format d'une date dans une chaîne de caractère [MySQL]
- GETDATE() obtenir la date courante du système, sans le décalage horaire [SQL Server]
- GETUTCDATE() obtenir la date courante UTC [SQL Server]
- HOUR() extraire le nombre d'heure pour une heure au format HH :MM :SS [MySQL]
- ISDATE() retourne 1 si la valeur en paramètre est dans l'un des formats suivants :

TIME, DATE ou DATETIME [SQL Server]
- ISFINITE() tester pour savoir si une date ou une période de temps est finie [PostgreSQL]
- JUSTIFY_HOURS() ajuster un intervalle de 24 heures en tant que "1 jour" ou un intervalle de 30 jours en tant que "1 mois" [PostgreSQL]
- LAST_DAY() retourner le dernier jour du mois d'une date [MySQL]
- LOCALTIME() synonyme de NOW() [MySQL, PostgreSQL]
- LOCALTIMESTAMP() synonyme de NOW() [MySQL, PostgreSQL]
- MAKEDATE() retourne une date à partir d'une année et du numéro du jour dans cette année [MySQL]
- MAKETIME() créer une heure au format TIME à partir d'une heure, des minutes et du nombre de secondes [MySQL]
- MICROSECOND() retourne le nombre de microsondes à partir d'une heure ou d'un DATETIME [MySQL]
- MINUTE() extraire le nombre de minutes d'une heure au format HH :MM :SS [MySQL]
- MONTH() extraire le numéro du mois à partir d'une date [MySQL, SQL Server]
- MONTHNAME() retourne le nom du mois [MySQL]
- NOW() obtenir la date courante [MySQL, PostgreSQL]
- PERIOD_ADD() ajoute un nombre définie de mois à une période [MySQL]
- PERIOD_DIFF() retourne le nombre de mois entre 2 périodes définies [MySQL]
- QUARTER() Return the quarter from a date argument [MySQL]
- SEC_TO_TIME() convertir un nombre de secondes en une heure et minutes au format HH :MM :SS [MySQL]
- SECOND() extraire le nombre de secondes d'une heure au format HH :MM :SS [MySQL]
- STR_TO_DATE() convertir une chaîne de caractère en date [MySQL]
- SUBDATE() synonyme de DATE_SUB() lorsque la fonction est invoquée avec 3 arguments [MySQL]
- SUBTIME() soustraire une heure [MySQL]
- SWITCHOFFSET() retourne une valeur DATETIMEOFFSET en changeant le fuseau horaire [SQL Server]
- SYSDATE() retourne la date et l'heure courante [MySQL]
- SYSDATETIME() retourne le DATETIME (date et heure) de l'ordinateur sur lequel est installé la base de données [SQL Server]
- SYSDATETIMEOFFSET() retourne le DATETIMEOFFSET du système avec le décalage du fuseau horaire inclus [SQL Server]
- SYSUTCDATETIME() retourne le DATETIME en heure UTC de l'ordinateur sur lequel la base est installées [SQL Server]
- TIME_FORMAT() formater une date dans un autre format [MySQL]
- TIME_TO_SEC() convertir une heure de format HH :MM :SS en nombre de secondes [MySQL]
- TIME() extraire l'heure/minutes/secondes au format HH :MM :SS à partir d'une date [MySQL]
- TIMEDIFF() retourne la durée entre 2 heures [MySQL]
- TIMESTAMP() permet de convertir une DATE au format DATETIME [MySQL]
- TIMESTAMPADD() ajoute un intervalle à une expression au format DATETIME

[MySQL]
- TIMESTAMPDIFF() soustraire un intervalle à partir d'une expression au format DATETIME [MySQL]
- TIMEOFDAY() retourne la date et heure courante [PostgreSQL]
- TO_DAYS() retourne le nombre de jour à partir d'une date [MySQL]
- TO_SECONDS() Return the date or datetime argument converted to seconds since Year 0 [MySQL]
- TODATETIMEOFFSET() retourne un DATETIMEOFFSET à partir d'un DATETIME [SQL Server]
- UNIX_TIMESTAMP() retourner le timestamp UNIX (nombre de secondes depuis le 1er janvier 1970) [MySQL]
- UTC_DATE() retourne la date GMT courante [MySQL]
- UTC_TIME() retourne l'heure GMT courante [MySQL]
- UTC_TIMESTAMP() retourne la date et heure GMT courante [MySQL]
- WEEK() déterminer le numéro de la semaine dans une année, à partir d'une date [MySQL]
- WEEKDAY() déterminer le jour de la semaine à partir d'une date (0=lundi, 1 :mardi, 2=mercredi ...) [MySQL]
- WEEKOFYEAR() déterminer le numéro de la semaine dans une année, à partir d'une date [MySQL]
- YEAR() extraire l'année d'une date [MySQL, SQL Server]
- YEARWEEK() retourne l'année et la semaine à partir d'une date [MySQL]

7 Logique Conditionnelle

7.1 COALESCE

La fonction `COALESCE` est utilisée pour remplacer les valeurs NULL par une valeur par défaut que l'on spécifie. On écrit alors :

```
COALESCE(expression, valeur_par_defaut)
```

De ce fait si l'expression n'est pas NULL, elle retourne sa valeur et si l'expression est NULL, elle retourne valeur_par_defaut.

7.2 NULLIF

La fonction `NULLIF` compare deux expressions et retourne `NULL` si elles sont égales. Sinon, elle retourne la première expression.

```
NULLIF(expression1, expression2)
```

Utilisé pour éviter une division par zéro :

```
SELECT total / NULLIF(count, 0) AS moyenne
FROM Table;
```

Si count = 0, alors NULLIF(count, 0) retourne NULL, évitant ainsi une erreur de division par zéro.

7.3 CASE WHEN

La structure `CASE WHEN` est une instruction conditionnelle utilisée pour évaluer des expressions et retourner une valeur en fonction d'une condition.

```
CASE WHEN condition THEN resultat ELSE resultat_defaut END
```

Dans un cas multi-conditions :

```
CASE
WHEN condition1 THEN resultat1
WHEN condition2 THEN resultat2
ELSE resultat_defaut
END
```

Exemple d'utilisation : calculer des agrégats conditionnels, comme compter les confirmations réussies :

```
SUM(CASE WHEN action = 'confirmed' THEN 1 ELSE 0 END) AS confirmed_count
```

Ici, on compte seulement les lignes où action = 'confirmed'.

7.4 IF

La fonction `IF()` renvoie une valeur si une condition est VRAIE, ou une autre valeur si une condition est FAUSSE.

Voici la syntaxe :

```
IF(condition, value_if_true,
value_if_false)
```

Voici des exemples :

```
SELECT IF(500 < 1000, 5, 10);
SELECT IF(500<1000, "YES", "NO");
```

Un autre exemple :

```
SELECT
    OrderID,
    Quantity,
    IF(Quantity>10, "MORE", "LESS")
FROM OrderDetails;
```

7.5 EXISTS

Dans le langage SQL, la commande `EXISTS` s'utilise dans une clause conditionnelle pour savoir s'il y a une présence ou non de lignes lors de l'utilisation d'une sous-requête.

Voici la syntaxe :

```
SELECT nom_colonne1
FROM table1
WHERE EXISTS (
    SELECT nom_colonne2
    FROM table2
    WHERE nom_colonne3 = 10);
```

Important : cette commande n'est pas à confondre avec la clause IN. La commande `EXISTS` vérifie si la sous-requête retourne un résultat ou non, tandis que IN vérifie la concordance d'une à plusieurs données.

7.6 GREATEST et LEAST

En SQL, les fonctions `GREATEST()` et `LEAST()` permettent de comparer plusieurs expressions (colonnes, valeurs littérales, variables, etc.) et de récupérer respectivement la plus grande ou la plus petite valeur parmi ces arguments.

— GREATEST(val1, val2, ...) : retourne la valeur maximale parmi les arguments transmis.

— LEAST(val1, val2, ...) : retourne la valeur minimale parmi les arguments transmis.

Ces fonctions sont disponibles dans plusieurs SGBD, notamment MySQL, PostgreSQL et Oracle. Elles ne font pas partie du core standard SQL ISO, mais sont très largement supportées.

Voici la syntaxe :

```
SELECT
    employe_id,
    GREATEST(salaire, prime, bonus) AS montant_max,
    LEAST(salaire, prime, bonus) AS montant_min
FROM contrats;
```

Points importants :

— Renvoie NULL : si un des arguments est NULL, la plupart des implémentations (par exemple MySQL, PostgreSQL, Oracle) retournent NULL (sauf configuration particulière).

— Nombre d'arguments : on peut passer 2, 3, 4 ou plus de valeurs à comparer, sous forme de champs ou de valeurs constantes.

— Type de retour : les SGBD essaient souvent de promouvoir ou de convertir les valeurs pour qu'elles soient comparables. Il est préférable que les arguments soient du même type ou de types compatibles.

8 Opérations de pivotement

L'opérateur `PIVOT` dans SQL Server et Oracle est une technique extrêmement utile qui transforme les tableaux en colonnes.

Transformez vos données de lignes en colonnes (ou vice-versa) pour une meilleure visualisation et analyse.

Utilité : Essentiel pour créer des rapports croisés dynamiques ou pour préparer les données pour une visualisation.

8.1 PIVOT

L'opérateur SQL Server `PIVOT` est utile pour résumer des données car il permet de transformer des lignes en colonnes.

Examinons le tableau city_sales ci-dessous, qui indique les ventes générales d'un produit dans cinq grandes villes des États-Unis.

	city	year	sales
1	New York	2019	1000
2	New York	2019	1100
3	New York	2020	1500
4	New York	2020	1600
5	New York	2021	2000
6	Los Angeles	2019	1100
7	Los Angeles	2019	1150
8	Los Angeles	2020	1600
9	Los Angeles	2020	1650
10	Los Angeles	2021	2100
11	Chicago	2019	1200
12	Chicago	2019	1250
13	Chicago	2020	1700
14	Chicago	2020	1750
15	Chicago	2021	2200

Nous allons utiliser la requête suivante, qui utilise l'opérateur PIVOT, pour faire pivoter plusieurs colonnes dans le tableau ci-dessus :

```sql
-- Select the columns for the output: city and sales data for 2019, 2020, ar`02
SELECT
    city,
    [2019] AS Sales_2019,
    [2020] AS Sales_2020,
    [2021] AS Sales_2021
FROM
    (
        -- Subquery to select city, year, and sales from city_sales table
        SELECT city, year, sales
        FROM city_sales
    ) AS src
PIVOT
(
    -- Pivot the sales data to have years as columns and sum the sales for each y
    SUM(sales)
    FOR year IN ([2019], [2020], [2021])
) AS pvt;
```

On obtient alors :

	city	Sales_2019	Sales_2020	Sales_2021
1	Chicago	2450	3450	2200
2	Houston	2650	3650	2300
3	Los Angeles	2250	3250	2100
4	New York	2100	3100	2000

8.2 UNPIVOT

UNPIVOT est un opérateur relationnel qui nous permet de convertir des colonnes en lignes dans une table (l'inverse de PIVOT).

Pour plus de détails : `https://www.geeksforgeeks.org/unpivot-in-sql-server/`

9 Les expressions régulières en SQL

9.1 Définitions et Bases

Une expression régulière, plus communément appelée REGEX (REGular EXpression) permet de faire des recherches et de la reconnaissance sur des chaînes de caractères.

Par exemple on peut extraire des numéros de téléphone d'une chaîne de caractère, ou vérifier que l'email ressemble bien à un email, exemple :

- **Adresses email** : *^[a-zA-Z0-9._%+-]+@[a-zA-Z0-9.-]+\.[a-zA-Z]{2,}$*
- **Numéros de téléphone** : *^\+?[1-9]\d{1,14}$*

Il ne s'agit pas d'un langage de programmation à proprement parler : la quasi-intégralité des langages dispose d'une bibliothèque REGEX permettant l'utilisation des expressions régulières.

De plus, la syntaxe ne varie que très peu d'un langage ou d'un outil à l'autre, ce qui facilite grandement la compatibilité entre les différentes plateformes.

En SQL, on s'en servira entre autres pour la validation des données, l'extraction de motifs complexes ou le nettoyage de texte à grande échelle.

Voici un tableau récapitulatif :

Caractère	Signification
^	**Début** d'une ligne
$	**Fin** d'une ligne
.	Correspond **à n'importe** quel caractère
\s	Correspond à un **espace**
\S	Correspond à n'importe quel caractère **sauf l'espace**
*	**Répète** un carctère **zéro** ou **plusieurs fois**
+	**Répète** un carctère **une** ou **plusieurs fois**
[^XYZ]	Correspond à un caractère unique **qui n'est pas** dans la liste XYZ
[a-z0-9]	Correspond aux lettres minuscules de **A à Z** ou chiffres de **0 à 9**
[[:alpha:]]	Correspond aux lettres **minuscules ou majuscules**
[[:punct:]]	Correspond aux **ponctuations**
\w	Correspond à n'importe quel caractère **alphanumérique ([a-zA-Z0-9]**
\W	Correspond à n'importe quel caractère **non alphanumérique ([^a-zA-Z0-9])**
\d	Correspond à n'importe quel caractère **numérique**
\D	Correspond à n'importe quel caractère **non numérique**
(	Indique **le début de l'extraction** de la chaîne
)	Indique **la fin de l'extraction** de la chaîne
R|S	L'expression régulière **R ou S**
Quantificateurs	
?	Répète un caractère **zéro** ou **une fois**
*	Répète un caractère **zéro** ou **plusieurs fois**
+	Répète un caractère **une** ou **plusieurs fois**
{n}	Répétition **n fois** consécutives
{n,m}	Répétition **n** à **m fois** consécutives
{,n}	Répétition **zéro** à **n fois** consécutives
{n,}	Répétition au moins **n fois** consécutives
Les caractères spéciaux	
[ ] { } ( ) \ ^ $. | ? * +	Ces caractères sont **spéciaux**. Pour les afficher, il faut au préalable **les échaper avec **

9.2 Exemples et astuces

En SQL (avec LIKE), le % est un joker qui signifie n'importe quelle suite de caractères. C'est vraiment le symbole principal que l'on utilisera

On pourra le placer avant ou après la cible de la requête.

Supposons qu'on cherche tous les patients atteints du diabète. Une colonne indiquera si c'est le cas avec un code DIAB1.

Voici la syntaxe :

```
SELECT *
FROM Patients
WHERE conditions LIKE "%DIAB1%" OR conditions LIKE "DIAB1%
```

On pourra également directement faire du REGEX dans un WHERE. Par exemple pour trouver toutes les adresses mails valides de @leetcode.com :

```
SELECT *
FROM Users
WHERE mail REGEXP '^[a-zA-Z][a-zA-Z0-9_.-]*@leetcode[.]com$';
```

9.3 Ressources utiles

Pour faire rapidement du REGEX ou vérifier son expression :

— N'importe quel LLM (Chat GPT ou autre)
— `https://regex101.com/`
— `https://regexlearn.com/fr`

10 Fenêtres analytiques/Fonctions de fenêtrages (Window Functions)

Les fonctions de fenêtrage vous permettent d'effectuer des calculs sur un ensemble de lignes liées à la ligne actuelle.

Idéal pour les calculs de classement, les moyennes mobiles, ou les totaux cumulatifs sans avoir à utiliser de sous-requêtes complexes.

Vous pouvez également entendre parler de fonctions de fenêtrage en SQL, de fonctions analytiques ou de fonctions OVER().

10.1 Qu'est-ce qu'une fenêtre ?

Un ensemble de lignes liées à la ligne courante est appelé une fenêtre ou un cadre de fenêtre. D'où le nom de ces fonctions : leur résultat est basé sur un cadre de fenêtre coulissante.

10.2 OVER(PARTITION BY...)

L'expression SQL `PARTITION BY` est une sous-clause de la OVER clause, qui est utilisée dans presque toutes les invocations de fonctions de fenêtre telles que `AVG()`, `MAX()` et `RANK()`.

La `PARTITION BY` sous-clause SQL est utilisée pour définir les enregistrements à inclure dans le cadre de fenêtre associée à chaque enregistrement du résultat.

Voici comment utiliser la `PARTITION BY` clause SQL à travers un exemple :

marque_de_voiture	modèle_de_voiture	type_de_voiture	prix_de_la_voiture
Gué	Mondeo	prime	18200
Renault	Feu	sport	16500
Citroën	Cactus	prime	19000
Gué	Faucon	faible coût	8990
Gué	Galaxie	standard	12400
Renault	Mégane	standard	14300
Citroën	Picasso	prime	23400

Pour chaque voiture, nous souhaitons obtenir la marque, le modèle, le prix, le prix moyen de toutes les voitures et le prix moyen du même type de voiture (pour avoir une meilleure idée de la façon dont le prix d'une voiture donnée se compare à celui des autres voitures). Voici la requête :

```
SELECT
      car_make,
      car_model,
      car_price,
      AVG(car_price) OVER() AS "overall average price",
      AVG(car_price) OVER (PARTITION BY car_type) AS "car type average price"
FROM car_list_prices;
```

Le résultat de cette requête est :

marque_de_voiture	modèle_de_voiture	prix_de_la_voiture	prix moyen global	type de voiture prix moyen
Gué	Mondeo	18200	16112.85	20200,00
Renault	Feu	16500	16112.85	16500,00
Citroën	Cactus	19000	16112.85	20200,00
Gué	Faucon	8990	16112.85	8990,00
Gué	Galaxie	12400	16112.85	13350,00
Renault	Mégane	14300	16112.85	13350,00
Citroën	Picasso	23400	16112.85	20200,00

La requête ci-dessus utilise deux fonctions de fenêtre. La première est utilisée pour calculer le prix moyen de toutes les voitures de la liste de prix. Elle utilise la fonction de fenêtre AVG()avec une OVER clause vide. La deuxième fonction de fenêtre est utilisée pour calculer le prix moyen d'un produit spécifique car_type comme standard, premium, sport, etc. C'est là que nous utilisons une OVER clause avec une PARTITION BY sous-clause.

Autre exemple : SUM(ventes) OVER (PARTITION BY produit ORDER BY date)

10.3 ROW_NUMBER

`ROW_NUMBER` est une valeur temporaire calculée lorsque la requête est exécutée. Elle numérote toutes les lignes dans l'ordre (par exemple 1, 2, 3, 4, 5).

Exemple :

```
SELECT
      ROW_NUMBER() OVER(ORDER BY name ASC) AS Row#,
      name,
      recovery_model_desc
FROM sysdatabases
WHERE database_id < 5;
```

Remarque : Vous devez déplacer la clause `ORDER BY` vers le haut jusqu'à la clause `OVER`.

10.4 RANK

Retourne le rang de chaque ligne au sein de la partition d'un jeu de résultats. Le rang d'une ligne est un, plus le nombre de rangs précédant la ligne en question.

RANK fournit la même valeur numérique pour les liens (par exemple 1, 2, 2, 4, 5).

10.5 LAG() et LEAD()

11 Mettre à jour une base de données

ATTENTION : Ce sont des commandes à manipuler avec précaution.

Avant d'essayer de modifier des lignes, il est recommandé d'effectuer une sauvegarde de la base de données, ou tout du moins de la table concernée par la modification. Ainsi, s'il y a une mauvaise manipulation il est toujours possible de restaurer les données.

11.1 UPDATE

La commande UPDATE permet d'effectuer des modifications sur des lignes existantes. Très souvent cette commande est utilisée avec WHERE pour spécifier sur quelles lignes doivent porter la ou les modifications.

Syntaxe :

```
UPDATE table
SET nom_colonne_1 = nouvelle valeur
WHERE condition
```

Pour spécifier en une seule fois plusieurs modification, il faut séparer les attributions de valeur par des virgules. Ainsi la syntaxe deviendrait la suivante :

```
UPDATE table
SET colonne_1 = valeur 1, colonne_2 = valeur 2,colonne_3 = valeur 3
WHERE condition
```

Exemple : Update the patients table for the allergies column. If the patient's allergies is null then replace it with 'NKA' :

```
UPDATE patients
SET allergies = 'NKA'
WHERE allergies IS NULL;
```

11.2 DELETE

La commande DELETE permet de supprimer des lignes dans une table. En utilisant cette commande associé à WHERE il est possible de sélectionner les lignes concernées qui seront supprimées.

Voici la syntaxe :

```
DELETE FROM table
WHERE condition;
```

Attention : s'il n'y a pas de condition WHERE alors toutes les lignes seront supprimées et la table sera alors vide.

11.3 TRUNCATE

Pour supprimer toutes les lignes d'une table, il est aussi possible d'utiliser la commande TRUNCATE, de la façon suivante :

```
TRUNCATE TABLE utilisateur;
```

Cette requête est similaire. La différence majeure étant que la commande TRUNCATE va ré-initialiser l'auto-incrémente s'il y en a un. Tandis que la commande DELETE ne ré-initialise pas l'auto-incrément.

12 Boite à outils et Astuces

12.1 STRCMP

Fonction pour comparer deux strings.

La syntaxe est la suivante : STRCMP(string1, string2)

Renvoie :
— If string1 = string2, this function returns 0
— If string1 < string2, this function returns -1
— If string1 > string2, this function returns 1

12.2 IN

La commande IN ...
Très efficace pour définir une liste. Par exemple, si je veux afficher toutes les lignes concernant les patients dont l'id est 1, 45, 534, 879, 1000 alors j'écrirai :

```
SELECT *
FROM patients
WHERE patient_id IN (1, 45, 534, 879, 1000);
```

On le voit tout de suite, cela évitera d'écrire :

```
SELECT *
FROM patients
WHERE patient_id = 1
OR patient_id = 45
OR patient_id = 534
OR patient_id = 879
OR patient_id = 1000;
```

12.3 LIKE

La commande LIKE ..
Ainsi, pour sélectionner tous les prénoms commençant par la lettre C, on pourra écrire :

```
SELECT first_name
FROM customers
WHERE first_name LIKE "C%";
```

Ainsi, pour sélectionner tous les prénoms commençant par la lettre C et qui finisse par la lettre e, on écrira donc LIKE "C%e".
Enfin, si je veux afficher tous les patients dont le diagnostic contient le mot "malade", je ferai LIKE "%malade%".

12.4 BETWEEN ... AND ...

L'opérateur `BETWEEN` est utilisé dans une requête SQL pour sélectionner un intervalle de données dans une requête utilisant `WHERE`. L'intervalle peut être constitué de chaînes de caractères, de nombres ou de dates. L'exemple le plus concret consiste par exemple à récupérer uniquement les enregistrements entre 2 dates définies :

```
SELECT *
FROM table
WHERE nom_colonne BETWEEN 'valeur1' AND 'valeur2';
```

12.5 TRIM

La fonction `TRIM()` permet de supprimer des caractères au début et en fin d'une chaîne de caractère.

Le plus souvent la fonction `TRIM()` permet de supprimer les caractères invisibles, c'est-à-dire les caractères tels que l'espace, la tabulation, le retour à la ligne ou bien même le retour chariot.

Basiquement : SELECT TRIM(' Exemple ') ; renverra "Exemple" sans espaces.

12.6 CONCAT

Dans le langage SQL la fonction `CONCAT()` permet de concaténer les valeur de plusieurs colonnes pour ne former qu'une seule chaîne de caractère. Cette fonction SQL peut se révéler pratique pour mettre bout-à-bout les valeurs de plusieurs colonnes pour n'en afficher qu'une. C'est donc pratique pour afficher un résultat facile à lire tout en maintenant les données dans plusieurs colonnes pour une bonne maintenance des données.

Plusieurs façon de l'utiliser :

```
SELECT
    CONCAT(first_name, ' ', last_name) AS full_name
FROM patients;
```

OU

```
SELECT
    first_name || ' ' || last_name
FROM patients;
```

On peut également l'utiliser dans un `WHERE` :

```
SELECT id
FROM table
WHERE colonne1 = CONCAT(colonne2, colonne3);
```

12.7 GROUP_CONCAT

La fonction `GROUP_CONCAT()` permet de regrouper les valeurs non nulles d'un groupe en une chaîne de caractère. Cela est utile pour regrouper des résultats en une seule ligne autant d'avoir autant de ligne qu'il y a de résultat dans ce groupe.

Attention : la fonction GROUP_CONCAT() est actuellement disponible que pour MySQL. Les autres Systèmes de Gestion de Base de Données (SGBD) tel que PostgreSQL, SQLite ou SQL Server n'intègrent pas cette fonctionnalité.

Voici la syntaxe :

```
SELECT id, GROUP_CONCAT(nom_colonne)
FROM table
GROUP BY id;
```

Il est possible de choisir le caractère qui sert de séparateur en respectant la syntaxe suivante :

```
SELECT id, GROUP_CONCAT(nom_colonne SEPARATOR ',' )
FROM table
GROUP BY id;
```

Voici un exemple issu d'un des exercices de leet code :

Example 1:

Input:
Activities table:

sell_date	product
2020-05-30	Headphone
2020-06-01	Pencil
2020-06-02	Mask
2020-05-30	Basketball
2020-06-01	Bible
2020-06-02	Mask
2020-05-30	T-Shirt

Output:

sell_date	num_sold	products
2020-05-30	3	Basketball,Headphone,T-shirt
2020-06-01	2	Bible,Pencil
2020-06-02	1	Mask

La requête pour obtenir l'output est :

```
SELECT
    sell_date,
    COUNT(DISTINCT product) as num_sold,
    GROUP_CONCAT(DISTINCT product ORDER BY product ASC SEPARATOR ',')
    AS products
FROM Activities
GROUP BY sell_date;
```

12.8 REPLACE

La fonction `REPLACE` dans le langage SQL permet de remplacer des caractères alphanumérique dans une chaîne de caractère. Cela sert particulièrement à mettre à jour des données dans une base de données ou à afficher des résultats personnalisés.

```
SELECT REPLACE('Hello tout le monde', 'Hello', 'Bonjour');
```

12.9 CAST

La fonction `CAST()` est une fonction de transtypage qui permet de convertir une données d'un type en un autre. Il est par exemple possible de transformer une date au format DATETIME en DATE, ou l'inverse.

```
SELECT CAST( expression AS type );
```

12.10 Les chaînes de caractères

12.10.1 Fonctions MID, RIGHT, LEFT

La fonction RIGHT retourne un morceau d'une chaine de caractère, d'une longueur renseignée en paramètre et en commençant pas les caractères de droite. RIGHT(chaine_a_couper, 5) prendra les 5 caractères en partant de la droite.

La fonction LEFT retourne un morceau d'une chaine de caractère, d'une longueur renseignée en paramètre et en commençant pas les caractères de Gauche.

La fonction MID retourne un morceau d'une chaine de caractère, d'une longueur renseignée en paramètre et en commençant pas le caractère dont le numéro est aussi renseigné en paramètre.

12.10.2 Obtenir le nombre de caractères

On utilisera la fonction LENGTH(...)

12.10.3 Majuscule/Minsucule

— LCASE() transformer une chaine de characère en minsucule (ou LOWER)
— UCASE() transformer uen chaien de charactère en majuscule (Ou UPPER)

12.10.4 Segmenter une chaîne de caractère

On utilisera SUBSTRING() (Ou SUBSTR) pour segmenter une chaîne de caractère.
La fonction SUBSTRING() peut s'utiliser de 4 façons différentes, que voici :
— SUBSTRING(chaine, debut) : retourne la chaîne de caractère de "chaine" à partir de la position définie par "debut" (position en nombre de caractères)
— SUBSTRING(chaine FROM debut) : idem que précédent
— SUBSTRING(chaine, debut, longueur) : retourne la chaîne de caractère "chaine" en partant de la position définie par "debut" et sur la longueur définie par "longueur"
— SUBSTRING(chaine FROM debut FOR longueur) : idem que précédent

12.10.5 Gérer les Noms Propres

Savante combinaison des fonctions décrites précédemment :

```
SELECT user_id,
CONCAT(UPPER(LEFT(name,1)),LOWER(RIGHT(name,LENGTH(name)-1))) as name
FROM Users;
```

13 Le SQL dans la Data Analyse

13.1 Identifier les doublons

```
SELECT customer_id, COUNT(*)
FROM customers
GROUP BY customer_id
HAVING COUNT(*) > 1;
```

13.2 Identifier les valeurs NULL

```
SELECT *
FROM customers
WHERE status IS NULL
```

13.3 Vérifier la validité des valeurs

```
SELECT *
FROM products
WHERE price <= 0;
```

13.4 Vérifier les valeurs de date

```
SELECT *
FROM orders
WHERE order_date <"2022-01-01" OR order_date >"2022-12-31";
```

13.5 Vérifier l'intégrité des données

```
SELECT *
FROM orders
WHERE customer_id NOT IN (SELECT customer_id FROM customers);
```

13.6 Identifier les données orphelines

```
SELECT *
FROM orders
WHERE order_id NOT IN (SELECT DISTINCT order_id FROM order_details);
```

13.7 Vérifier si la quantité est un nombre

```
SELECT *
FROM order_details
WHERE TRY_CAST(quantity AS FLOAT) IS NULL;
```

13.8 Détecter les valeurs aberrantes à l'aide de l'IQR (Interquartile Range)

```
WITH Quartiles AS (
SELECT
PERCENTILE_CONT(0.25) WITHIN GROUP (ORDER BY valeur) AS Q1,
PERCENTILE_CONT(0.75) WITHIN GROUP (ORDER BY valeur) AS Q3
FROM ma_table),

IQR_Calcul AS (
SELECT Q1, Q3,
(Q3 - Q1) AS IQR,
(Q1 - 1.5 * (Q3 - Q1)) AS lower_bound,
(Q3 + 1.5 * (Q3 - Q1)) AS upper_bound
FROM Quartiles)

SELECT t.*
FROM ma_table t
JOIN IQR_Calcul iqr
ON t.valeur < iqr.lower_bound OR t.valeur > iqr.upper_bound;
```

13.9 Vérifier le format des adresses e-mail

```
SELECT *
FROM customers
WHERE email NOT LIKE "%_@__%.__%";
```

13.10 Valider les valeurs de la colonne status

```
SELECT DISTINCT status
FROM orders
WHERE status NOT IN ("Completed", "Pending", "Cancelled");
```

14 Bonnes pratiques

14.1 Commencez chaque nom de colonne sur une nouvelle ligne

Cela assure la clarté et la lisibilité, permettant de commenter facilement une colonne.

14.2 Utilisez des alias descriptifs et compréhensibles

Cette pratique améliore la lisibilité des requêtes et aide les autres à comprendre votre code plus facilement.

14.3 Évitez d'utiliser SELECT*

Spécifiez explicitement les colonnes dont vous avez besoin plutôt que d'utiliser * . L'étoile peut ralentir la performance des requêtes.

14.4 Évitez les sous-requêtes si possible

Utilisez des JOINs pour de meilleures performances.

14.5 Gérez les valeurs NULL

Les valeurs NULL peuvent créer des comportements inattendus dans vos requêtes SQL. Utilisez des fonctions comme COALESCE ou NULLIF pour les gérer.

14.6 Utilisez des commentaires

C'est une pratique de code à adopter le plus tôt possible. Pour commenter son code en SQL, on utilisera : "- -" avant la phrase de commentaire (deux tirets du six collés).

14.7 Commencez chaque colonne par une virgule

Au cas où vous commenteriez amount, votre code fonctionnera sans erreur.

14.8 Utilisez WHERE TRUE

Au cas où vous commenteriez status = 'completed', votre code fonctionnera sans erreur.

14.9 Organisez votre code avec des CTEs

La clause WITH rend le code lisible, car la requête principale n'est pas interrompue par les sous-requêtes.

14.10 Supprimez les clauses ORDER BY inutiles

La clause ORDER BY ajoute de la complexité et ralentit l'exécution, surtout quand vous travaillez avec de gros datasets. Utilisez-la si nécessaire !

15 Sources

Ce document s'appuie sur la documentation du langage, un grand nombre de cours présent sur Internet, sur mes lectures et tous les posts LinkedIn que j'ai pu trouver dans ce domaine.

Les sites :
- La doc du langage : https://sql.sh/
- Site de cours lié à la documentation : https://sql.sh/2143-cours-sql-pdf
- Super cours de SQL : https://enseignement.alexandre-mesle.com/sql/sql.pdf
- SQL Tutorial - Full Database Course for Beginners : https://www.youtube.com/watch?v=HXV3zeQKqGY
- https://mode.com/sql-tutorial
- https://generation-prepa.com/wpcontent/uploads/2021/12/SQL.pdf
- https://learnsql.com/cookbook/how-to-get-the-year-and-the-month-from-a-date-in-mysql/
- Cours de leetcode : https://leetcode.com/explore/featured/card/sql-language/
- https://webusers.i3s.unice.fr/~rueher/Cours/BD/DocPostgresSQL9-5_HTML/datatype.html
- TOP-70 Most Important SQL Queries in 2023 : https://bytescout.com/blog/20-important-sql-queries.html
- https://learnsql.fr/blog/qu-est-ce-qu-une-expression-de-table-commune-cte-en-sql/
- https://www.datacamp.com/fr/tutorial/sql-pivot
- https://aws.amazon.com/fr/compare/the-difference-between-sql-and-mysql/#:~:text=MySQL%20et%20SQL%20Server%20sont,columnstore%20%C2%BB%20pour%20optimiser%20les%20performances.
- https://data.sigea.educagri.fr/download/sigea/supports/PostGIS/distance/perfectionnement/M04_complement_SQL/co/30_types_jointure.html#:~:text=Une%20jointure%20crois%C3%A9e%20(cross%20join,toutes%20les%20colonnes%20de%20t2.

Super site pour le Regex :
- https://regexlearn.com/fr
- https://datascientest.com/regex-tout-savoir
- https://regex101.com/
- https://community.alteryx.com/t5/Blog/Pense-bete-RegEx/ba-p/1239471

Super sites pour apprendre :
- W3School : https://www.w3schools.com/sql/
- SQL Bolt : https://sqlbolt.com/
- SQL Zoo : https://sqlzoo.net/wiki/SQL_Tutorial
- Select Star : https://selectstarsql.com/
- SQLTutorial : https://www.sqltutorial.org/
- Data Lemur : https://datalemur.com/

Les plateformes d'entraînement, à faire dans l'ordre :
— https://www.sql-practice.com/
— https://leetcode.com/studyplan/top-sql-50/
— https://www.sqlnoir.com/
— https://www.kaggle.com/code/dillonmyrick/sql-beginner-to-advanced-with-practical-examples

Mes sources LinkedIn et Newsletters :
— https://www.linkedin.com/in/gael-penessot/
— https://www.linkedin.com/in/fphuongnguyen/
— https://www.linkedin.com/in/fphuongnguyen/

La section Bonnes pratiques provient de ce lien : https://www.linkedin.com/posts/fphuongnguyen_10-tips-de-pro-pour-un-code-sql-impeccablepdf-ugcPost-7304754235194159105-xP0u?utm_source=share&utm_medium=member_desktop&rcm=ACoAADIZc5QB1CXXmYmgtD6_ZpOS4ATZsuRulXk